

Enterprise RAG Quality Benchmark Report

多文档 RAG 检索评估与质量门禁样例报告 - 约 8 页

1. Benchmark 背景与目标

本报告模拟一个企业 RAG 项目的质量基准测试。测试对象是一组包含 PDF、Excel、Markdown 和代码片段的混合语料。目标是比较不同 chunk 策略、embedding 模型、rerank 策略和表格解析方式对检索质量的影响。

报告强调一个核心观点：RAG 的质量不是由最终回答单独决定，而是由 ingestion、chunk、embedding、retrieval、rerank、answer synthesis 和 citation 多个环节共同决定。任何一个环节出现缺陷，都可能导致模型生成看似合理但没有证据支撑的答案。

测试维度	核心问题	观测指标
Chunking	切分是否保留语义完整性？	断句率、短碎 chunk 占比
Embedding	语义改写能否召回？	top-1/top-3 accuracy
Rerank	是否能把正确证据排到前面？	MRR、nDCG
Citation	答案能否追溯？	source coverage、引用准确率

2. 测试语料说明

本次 benchmark 使用四类文档。第一类是业务需求 PDF，包含章节标题、正文段落和表格。第二类是事故复盘 PDF，包含 root cause、timeline 和 corrective actions。第三类是供应商评估 Excel，包含评分表、风险登记表和 metadata sheet。第四类是简短代码文档，用于测试技术问答和符号级检索。

混合语料的价值在于测试跨文档问题。例如用户可能问“哪个供应商适合处理 table-aware parsing，并且对应风险有哪些”，系统需要同时检索 Excel 中的供应商评分和 PDF 中的 ingestion 风险描述。

语料	格式	页数/行数	主要挑战
enterprise_agent_requirements.pdf	PDF	约 10 页	中文章节、表格、权限描述
rag_ingestion_incident_postmortem.pdf	PDF	约 2 页	中英混合、事故时间线
vendor_evaluation.xlsx	Excel	3 个 sheet	多 sheet、评分、风险
code_notes.md	Markdown	若干段落	标题层级和代码块

3. Chunk 策略实验

实验比较三种策略：固定字符切分、段落感知切分、句子感知切分。固定字符切分实现最简单，但容易切断句子和表格。段落感知切分对文档问答更友好，但当段落过长时仍需兜底切分。句子感知切分通常能提高可读性，但需要更复杂的规则处理中文标点、英文缩写和列表。

结果显示，固定字符切分在 exact match query 上表现尚可，但在 paraphrase query 上不稳定。段落感知和句子感知策略能够让 top-3 accuracy 提升，尤其是在“为什么低质量 chunk 会影响检索结果”这类概念型问题上更明显。

策略	chunk_size	overlap	短碎 chunk	top-3 accuracy	备注
Fixed-800	800 chars	100 chars	12%	78%	实现简单，但断句较多
Paragraph-aware	动态	段落边界	7%	84%	适合普通 PDF 正文
Sentence-aware	900 chars	150 chars	5%	88%	更适合中文问答
Table-aware hybrid	正文+表格分流	按结构	4%	91%	实现复杂但效果最好

3.1 低质量 chunk 示例

低质量 chunk
常见形式包括：只有页码、目录点线、页眉页脚、孤立半句话、表格列头丢失、过长的混合段落。系统应该在 ingestion 阶段标记这些 chunk，而不是等到用户问答失败后再排查。

- 示例一：Text: 27
- 示例二：Text: 增加 / 能力而获益？
- 示例三：表格被摊平成属性、所选安排、说明、概要/逻辑性，但列关系无法恢复。

4. Retrieval Eval 设计

Retrieval eval 的最小单元是一条 query、一个 expected source 或 expected chunk，以及 top-k 结果。早期不需要复杂指标，先人工检查 top-1 是否相关、top-3 是否包含答案、是否返回目录噪声。稳定之后再引入 MRR、Recall@k、nDCG 和 label-based scoring。

建议将 query 分成三类：near-exact query、paraphrase query 和 cross-document query。near-exact query 用于验证链路是否跑通；paraphrase query 用于验证 embedding 语义能力；cross-document query 用于验证 metadata filter、multi-source retrieval 和 answer synthesis。

Query 类型	例子	目标	通过标准
Near-exact	如果项目中的任何合同被归类为战术获得	链路验证	Top-1 命中原文页
Paraphrase	低风险合同为什么不需要很多分析？	语义召回	Top-3 命中相关段落
Cross-document	哪个供应商最适合表格解析？	多源检索	命中 Excel 评分与 PDF 风险
Negative	文档有没有提到火星基地预算？	防幻觉	返回无证据或低置信度

5. Rerank 与 Query Rewrite

当语料规模变大时，仅靠 embedding top-k 往往不够。Rerank 可以在初步召回后重新排序，把更精确的证据放到前面。Query rewrite 则可以把用户的口语化问题改写成更适合检索的关键词组合。但二者都可能引入额外成本和延迟，因此应通过 eval 数据决定是否需要。

在本 benchmark 中，rerank 对表格型问题和跨文档问题提升明显。对于 near-exact query，rerank 提升有限。对于 negative query，rerank 不能替代证据不足判断，系统仍需要设置最低相似度阈值和 fallback policy。

方法	适用场景	收益	代价
Query Rewrite	口语化、模糊问题	召回更稳定	可能偏离用户原意
BM25 + Embedding Hybrid	关键词和语义都重要	兼顾专有名词	索引复杂度增加
Cross-encoder Rerank	top-k 候选较多	排序精度高	延迟和成本增加
Metadata Filter	按 source/page/sheet 限制	减少噪声	依赖 metadata 质量

6. Answer Grounding 与 Citation 检查

最终答案必须 grounded in retrieved evidence。生成器不应该把多个 chunk 的内容随意拼接成没有来源的结论。对于企业场景，答案需要明确指出依据来自哪个文档、哪一页或哪个 sheet。对于 Excel 数据，引用还应包含 sheet_name 和 row range。

Citation 检查可以分为覆盖率和准确率。覆盖率表示答案中关键事实是否都有引用；准确率表示引用的 chunk 是否真的支持对应事实。很多系统只做到“看起来有引用”，但引用并不支持答案，这是生产环境中很危险的问题。

检查项	说明	失败例子
source coverage	每个关键事实至少一个 source	答案说有 39% 提效但没有出处
citation accuracy	引用内容支持该事实	引用权限表来证明成本下降
quote boundary	引用片段不要越界	把两个无关段落合并引用
no evidence fallback	无证据时明确说明	编造文档没有的结论

7. 结果摘要与建议

本 benchmark 的结论是：在小语料场景中，最重要的不是追求复杂的向量数据库，而是做好文档解析、chunk 质量、metadata、人工抽样和最小 retrieval eval。只有当 top-k 能稳定命中正确证据时，接入 LLM 生成答案才有意义。

对于当前 demo，建议先实现多文件 ingestion、PDF/Excel 分流解析、chunk 质量报告、top-k 检索可视化和 20 条 golden queries。然后再逐步加入 hybrid search、rerank、answer generation 和自动 citation check。

- 第一优先级：过滤低质量 chunk，保留 source/page/chunk_id/sheet_name。
- 第二优先级：建立 retrieval eval 表，覆盖 exact、paraphrase、cross-document 和 negative query。
- 第三优先级：对表格文档做 table-aware parsing，把表格转 markdown 或 JSON。
- 第四优先级：接入 LLM 前先单独验证 retriever。

8. 附录：Golden Queries

以下 queries 可直接用于本 demo corpus 的检索评估。每条 query 都应记录 top-1 chunk、top-3 chunks、score、是否相关、失败原因。长期维护这类 golden set，可以在修改 chunk 策略、embedding 模型或 rerank 配置后快速发现回归。

ID	Query	类型	期望命中
Q01	RAG ingestion 为什么不能直接把文件丢进向量库？	paraphrase	enterprise requirements 第 5 章
Q02	哪些 chunk 应该被标记为低质量？	fact	benchmark 第 3.1 节
Q03	Maintainer 的工具权限是什么？	fact	enterprise requirements 第 3 章
Q04	哪个供应商得分最高？	cross-document	vendor_evaluation.xlsx
Q05	事故复盘中提出了哪些 corrective actions？	cross-document	postmortem PDF
Q06	文档有没有提到火星基地预算？	negative	应返回无证据